

Analisi Numerica

Sebastiano Boscarino

April 26, 2026

Sistemi Indeterminati

Sistemi lineari di $m \times n$ con $m \neq n$. Sia $Ax = b$ con $A \in \mathbb{R}^{m \times n}$ sistema rettangolare.

- $m > n$ (caso sovradeterminato): estraiamo dalla matrice rettangolare A una sotto-matrice quadrata di ordine n ; sia k il rango (max num. righe o colonne l.ind.) della matrice di A :
 - $k(A) \neq k(A, b)$ sistema incompatibile $K(A, b) > n$;
 - $k(A) = k(A, b)$ sistema compatibile $K(A) = n$ soluzione unica, $k(A) < n$, $\infty^{n-k(A)}$ soluzioni!
 - Il sistema quindi potrebbe non avere soluzione. Il sistema è detto sovradeterminato!
- $m < n$ (caso sottodeterminato): si può estrarre dalla matrice rettangolare A una sotto-matrice quadrata di ordine m ; sia k il rango della matrice A . Poiché $k \leq m < n$, il sistema non potrà mai avere una ed una sola soluzione!
 - $k(A) \neq k(A, b)$ sistema incompatibile;
 - $k(A) = k(A, b)$ sistema compatibile $k(A) < n \infty^{n-k(A)}$ soluzioni!
 - Il problema può avere infinite soluzioni. Il sistema è detto sottodeterminato;

Minimi quadrati

Siano i dati (x_i, y_i) con $i = 1, 2, \dots, m$ i punti che rappresentano i dati di un certo esperimento. Si vuole trovare un modello $F(x_i; \mathbf{c})$, con $\mathbf{c} = (c_1, c_2, \dots, c_n)$ vettore di parametri, con $m > n$, tale che approssimi la successione dei punti dati, ovvero:

$$y_i = F(x_i; \mathbf{c}) + r_i, \quad i = 1, \dots, m$$

con $\mathbf{r} = (r_1, r_2, \dots, r_m)$ vettore dei residui, tra i valori misurati dal modello e quelli previsti y_i . Il problema che si pone consiste nel determinare i parametri c_i in modo che sia minima la norma del residuo $\mathbf{r}$.

Questa può essere determinata minimizzando la distanza (euclidea) ossia la quantità:

$$\|\mathbf{r}\|_2^2 = \sum_{i=1}^m (y_i - F(x_i; \mathbf{c}))^2,$$

da cui il nome **minimi quadrati**.

Minimi quadrati

Se scegliamo come modello F quello lineare ovvero

$$F(x; \mathbf{c}) = c_1\varphi_1(x) + \varphi_2(x)c_2 + \dots + \varphi_n(x)c_n$$

con $\varphi_j(x)$ funzioni di base che nel caso della base canonica $\varphi_j(x) = x^j$, con $j = 0, 1, \dots, n-1$.

Caso particolare con $n = 2$ abbiamo

$$F(x; \mathbf{c}) = c_1x + c_2.$$

Il metodo dei minimi quadrati è una tecnica di ottimizzazione (o regressione) che permette di trovare una funzione (modello), rappresentata da una curva ottima (o curva di regressione), che si avvicini il più possibile ad un insieme di dati (tipicamente punti del piano). Quindi, la funzione trovata (o modello) deve essere quella che minimizza la somma dei quadrati delle distanze tra i dati osservati y_i e quelli della curva che rappresenta la funzione stessa.

Sistemi sovradeterminati

Supponiamo il modello precedente $F(x; \mathbf{c}) = c_1x + c_2$, e i dati (x_i, y_i) : $(-1, 2), (-0, 5.1), (0, 0.5), (0.5, 1.5), (1, 2.5)$, da cui segue

$$A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ x_4 & 1 \\ x_5 & 1 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ -0.5 & 1 \\ 0 & 1 \\ 0.5 & 1 \\ 1 & 1 \end{pmatrix}$$

$$\mathbf{r} = \mathbf{y} - A\mathbf{c} = \begin{pmatrix} 2 \\ 1 \\ 0.5 \\ 1.5 \\ 2.5 \end{pmatrix} - \begin{pmatrix} -1 & 1 \\ -0.5 & 1 \\ 0 & 1 \\ 0.5 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$$

Sistemi sovradeterminati

Sia fatta attenzione sul primo caso, $(m > n)$ frequente nelle applicazioni: il numero di equazioni m è superiore al numero delle incognite n .

Nel caso specifico di sistemi sovradeterminati è ragionevole richiedere che sia minima la lunghezza euclidea del vettore residuo (detta anche varianza). Il problema dei minimi quadrati, si esplica nella condizione di varianza minima

$$\min_{x \in \mathbb{R}^n} \|r\|_2^2 := \min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

Metodo dei minimi quadrati

Data una matrice $A \in \mathbb{R}^{m \times n}$ e un vettore $b \in \mathbb{R}^m$, si dice che $x^* \in \mathbb{R}^n$ è soluzione nel senso dei minimi quadrati del sistema lineare $Ax = b$ se:

$$\Phi(x^*) = \|Ax^* - b\|_2^2 \leq \|Ax - b\|_2^2 = \Phi(x) \quad \forall x \in \mathbb{R}^n.$$

Dove $\|\cdot\|_2$ rappresenta la norma euclidea.

Si tratta quindi di minimizzare il residuo nella norma euclidea

$$\min_{x \in \mathbb{R}^n} \|r\|_2^2 := \min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

Metodo dei minimi quadrati

La soluzione del problema precedente può essere ottenuta imponendo che il gradiente della funzione Φ si annulli nel punto x^* .

Si definisce gradiente un operatore del primo ordine che associa ad ogni campo scalare il campo vettoriale le cui componenti sono le derivate parziali prime: $\nabla\Phi = \left(\frac{\partial\Phi}{\partial x_j}\right)_{1 \leq j \leq n}$.

Essendo

$$\begin{aligned}\Phi(x) &= (Ax - b)^T (Ax - b) = x^T A^T Ax - x^T A^T b - b^T Ax + b^T b = \\ &= x^T A^T Ax - 2x^T A^T b + b^T b\end{aligned}$$

$$\nabla\Phi(x^*) = 2A^T Ax^* - 2A^T b = 0$$

Da cui si deduce che x^* è soluzione del sistema

$$A^T Ax^* = A^T b$$

Noto come **sistema normale** delle equazioni. Tale sistema è non singolare se A ha rango pieno.

Metodo dei minimi quadrati

LA matrice $A^T A$ è simmetrica e definita positiva, quindi è possibile applicare il metodo di Cholesky per fattorizzare opportunamente il sistema normale.

Tuttavia il sistema delle equazioni normali è spesso mal condizionato e gli errori introdotti nei dati e nel processo di approssimazione tendono ad amplificarsi, e quindi in genere $A^T A$ mal condizionamento, con perdita di positività o di non singularità della matrice $A^T A$.

Alternativa all'equazioni normali. Le trasformazioni ortogonali non cambiano la norma euclidea

$$\|Q^T r\|_2^2 = (Q^T r)^T (Q^T r) = (r^T Q)(Q^T r) =$$

$$r^T (Q Q^T) r = r^T r = \|r\|_2^2,$$

ovvero non altera la norma 2-del residuo. Quindi segue:

$$\|Q^T (Ax - b)\|_2^2 = (Q^T r)^T (Q^T r) = r^T (Q Q^T) r = r^T r = \|Ax - b\|_2^2,$$

Quindi in generale è più conveniente impiegare la fattorizzazione **QR**.

$$\|Ax - b\|_2^2 = \|QRx - b\|_2^2 = \|Q(Rx - Q^T b)\|_2^2 = \|Rx - c\|_2^2,$$

con $c = R^T b$. Allora si ha

Theorem

Sia $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ una matrice di rango pieno. Allora l'unica soluzione del P.M.Q. è dato da $x^ = \tilde{R}^{-1} \tilde{Q}^T b$, essendo $\tilde{R} \in \mathbb{R}^{n \times n}$ e $\tilde{Q} \in \mathbb{R}^{m \times n}$ matrici determinate a partire dalla fattorizzazione QR di A.*

Un modo più robusto rispetto alle equazioni normali, o al metodo QR , si basa sulla decomposizione SVD .

Se una matrice $A \in \mathbb{R}^{m \times n}$ con $m \geq n$, la decomposizione SVD è

$$A = U \Sigma V^T,$$

con $U \in \mathbb{R}^{m \times m}$ e $V \in \mathbb{R}^{n \times n}$, matrici ortogonali e Σ una matrice diagonale, e i valori sulla diagonale sono detti **valori singolari**:

$\sigma_1 \geq \sigma_2 \geq \dots \sigma_n \geq 0$. Nel caso della decomposizione SVD il problema ai minimi quadrati è

$$\|Ax - b\|_2^2 = \|U \Sigma V^T x - b\|_2^2 = \|U^T (U \Sigma V^T x - b)\|_2^2 = \|\Sigma V^T x - U^T b\|_2^2.$$

Se poniamo $U^T b = d$ e $V^T x = z$ si ottiene

$$\|Ax - b\|_2^2 = \|\Sigma z - d\|_2^2.$$

Quindi consiste nel minimizzare l'espressione

$$E_2(z) = (\sigma_1 z_1 - d_1)^2 + (\sigma_2 z_2 - d_2)^2 + \dots + (\sigma_n z_n - d_n)^2 + d_{n+1}^2 + \dots + d_m^2.$$

Se tutti i valori singolari della matrice sono diversi da zero allora il minimo di $E_2(z)$ è assunto per

$$z_i = \frac{d_i}{\sigma_i}, \quad i = 1, \dots, n$$

e il valore minimo è uguale a

$$\|Ax - b\|_2^2 = d_{n+1}^2 + \dots + d_m^2.$$

Se qualche $\sigma_i = 0$ si sceglie $z_i = 0$.

Applicazione

Consideriamo una tabulazione $\{f(x_0), f(x_1), \dots, f(x_m)\}$ sull'insieme degli $m + 1$ nodi $\{x_0, x_1, \dots, x_m\}$ in $[a, b]$.

- **Interpolazione polinomio di grado n , con $n = m$** si cerca quella funzione (in una fissata famiglia di funzioni) che in opportuni punti (detti nodi) assume gli stessi valori della funzione da approssimare.
- **Migliore approssimazione polinomio di grado n con $m > n$:** si cerca quella funzione (in una fissata famiglia di funzioni) la cui “distanza” dalla funzione da approssimare risulta essere minima.

Migliore approssimazione

L'obiettivo è determinare un polinomio $p(x) \in P_n$, dove P_n rappresenta l'insieme dei polinomi di grado n , (con $m > n$), del tipo:

$$p(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0$$

tale che la distanza

$$\sum_{i=0}^m (f(x_i) - p(x_i))^2$$

sia minima tra tutti i polinomi di grado n . Si osservi che si sommano i quadrati delle distanze in ogni punto, da cui il nome **ai minimi quadrati**.

Sia data una funzione che corrisponde a una perturbazione di $\sin(x)$ in $[0, 2\pi]$.

- Per n che varia da 1 a 8 (grado del polinomio), determina i coefficienti del polinomio p_n di grado n che meglio approssima i dati (x_k, y_k) , $k = 1, \dots, 100$ nel senso dei minimi quadrati;
- Valutare $\|f - p_n\|_2$;
- Disegna in una stessa figura il grafico dei dati (x_k, y_k) , $k = 1, \dots, 100$ e il polinomio p_n , cambiando il titolo al variare del grado, e inserendo una legenda;

Regressione Lineare

Obiettivo: modellare la relazione tra input e output

Dato un dataset:

$$(x_i, y_i), \quad i = 1, \dots, n$$

Modello:

$$\hat{y}_i = w^T x_i + b$$

Parametri da stimare:

- w = pesi
- b = bias, b è un termine costante che non dipende da x_i

Se $w = (w_1, w_2, \dots, w_d)$ pesi e $x_i = (x_{i1}, x_{i2}, \dots, x_{id})$ feature, il prodotto scalare si legge

$$\hat{y}_i = \sum_{j=1}^d w_j x_{ij} + b$$

Metodo dei Minimi Quadrati

Errore (residuo):

$$r_i = y_i - \hat{y}_i$$

Problema di ottimizzazione:

$$\min_{w,b} \sum_{i=1}^n (y_i - (w^T x_i + b))^2$$

Forma matriciale:

$$\min_w \|Xw - y\|_2^2$$

- y Target;
- w parametri ($b = 0$);
- X matrice dei dati;

Due Modi per Risolvere

1. Soluzione analitica:

$$(X^T X)w^* = X^T y$$

2. Metodi di ottimizzazione:

- Gradient Descent
- Stochastic Gradient Descent (SGD)
- ADAM

Idea:

- aggiornamenti iterativi
- utile per problemi grandi o complessi

dove $L(w) = \|Xw - y\|_2^2$

Caratteristiche:

- semplice
- richiede scelta del learning rate η

Problemi di regressione lineare (curve fitting)

Per risolvere i problemi di regressione lineare, l'obiettivo è trovare una funzione f che mappa gli input $x \in \mathbb{R}^D$ ai valori $f(x) \in \mathbb{R}$. Abbiamo un set di dati di addestramento x_n e osservazioni rumorose $y_n - f(x_n) = \epsilon$, dove ϵ è il rumore.

L'obiettivo è trovare una funzione che si adatti ai dati di addestramento e che generalizzi bene per nuovi dati.

Regressione: Problemi principali

La regressione è un problema chiave nel machine learning e si applica in molti settori. Alcuni dei problemi principali sono:

- **Scelta del modello.** Quale tipo di funzione (ad esempio, polinomio) è adatto per i dati? E quale parametro (ad esempio, grado del polinomio) scegliere?
- **Selezione del modello.** Confrontare diversi modelli per trovare quello più semplice che spiega i dati.
- **Trovare i parametri.** Come ottimizzare i parametri del modello usando funzioni di perdita e algoritmi di ottimizzazione.
- **Overfitting.** L'overfitting si verifica quando il modello si adatta troppo ai dati di addestramento, ma non generalizza bene. È importante evitare questo problema.
- **Modellizzazione dell'incertezza.** Poiché i dati di addestramento sono limitati, dobbiamo considerare l'incertezza per migliorare la previsione sui nuovi dati.

Obiettivo

- Studiare metodi di ottimizzazione per minimizzare la funzione di errore in modelli di regressione e classificazione.
- Analizzare la convergenza degli algoritmi di ottimizzazione.
- Confrontare diversi approcci per migliorare le prestazioni.

Definizione del Problema

Regressione: minimizzazione dell'Errore Quadratico Medio (MSE)

$$\mathcal{L}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i, \theta))^2 \quad (1)$$

Classificazione: minimizzazione della Cross-Entropy Loss

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{y}_i(\theta) + (1 - y_i) \log(1 - \hat{y}_i(\theta))] \quad (2)$$

Dove:

- $\hat{y}_i$ è la probabilità predetta dal modello.
- n è il numero totale di campioni nel dataset.

Algoritmi di Ottimizzazione

- **Gradiente Discendente (GD)**: aggiornamento iterativo dei parametri.
- **Stochastic Gradient Descent (SGD)**: aggiorna i parametri su singoli campioni.
- **Momentum**: accelera la convergenza.
- **Adam**: combina SGD e Momentum per migliorare le prestazioni.
- **Gradiente Coniugato**: risolve il sistema lineare senza inversione esplicita.

Risultati Attesi

- Identificare il metodo più efficiente per diverse funzioni di errore.
- Studiare l'impatto del tasso di apprendimento sulla convergenza.
- Implementare un codice ottimizzato per la minimizzazione dell'errore.

Conclusioni

- L'ottimizzazione della funzione di errore è cruciale per modelli accurati.
- Diversi algoritmi presentano vantaggi in base al problema.
- L'analisi numerica aiuta a selezionare il miglior metodo di ottimizzazione.